

## 탄소배출권 거래시장 특성을 반영한 배출권가격 예측모델 개발

### The Study on Development of Carbon Emission Price Forecasting Model Reflecting Emission Trading Market Characteristics

김영민 · 안재준

Kim, Young Min · Ahn, Jae Joon

#### Abstract

본 연구의 목적은 탄소배출권 거래시장 특성이 반영된 탄소배출권 가격 예측 모델 개발이다. 이러한 예측 모델을 개발하기 위하여 본 연구에서는 탄소배출권 가격과 가장 밀접한 관련이 있다고 밝혀진 유가 데이터 (WTI Index)를 기반으로 다양한 파생변수들을 생성하여 입력변수로 사용하였으며, 반응변수인 탄소배출권 가격 흐름의 정상성을 확보하기 위하여 원시계열 데이터를 수익률로 변환시켜 모델을 구축하였다. 예측 모델에 활용된 알고리즘은 능형회귀분석과 인공신경망 알고리즘, 더 나아가 최종적으로 유전자 알고리즘을 기반으로 두 알고리즘이 조합된 하이브리드 예측 모델을 구축하였다. 또한, 능형회귀분석, 인공신경망, 다변량 회귀분석의 예측성과를 비교하였다. 그 결과 본 연구에서 제안한 모델의 예측성과가 개선됨을 확인할 수 있었으며, 제안된 모델을 검증하기 위하여 Sliding Window Method를 통해 모델의 유용성을 확인할 수 있었다.

**주제어 :** 탄소배출권 가격 예측 모델, 배출권 거래시장, 하이브리드 예측 모델

This study proposes a novel carbon emission price forecasting model reflected emission trading market characteristics. For building the forecasting model, various variables derived from WTI index, well known as representative of oil price, are used as input variables since the oil price is strongly correlated with carbon emission price. In addition, raw data of carbon emission price is transformed into the rate of return for stationarity of response variable. Artificial neural network (ANN) and ridge regression (RR) is employed for the forecasting model and these two predicting algorithms are combined by genetic algorithm as a hybrid prediction model. The predictive performance of the forecasting model developed in this study is compared to other algorithms such as multiple regression, pure RR, and pure ANN. As a result, we can verify that the predictive performance of our model is improved. To verify the predictive performance, a sliding window method is applied in this study.

**Keywords :** Carbon Emission Price Forecasting Model, Emission Trading Market, Hybrid Prediction Model

김영민: Missouri University of Science and Technology, Department of Engineering Management and Systems Engineering, Post-doc(제1저자)  
안재준: 연세대학교, 정보통계학과, 조교수(교신저자)

## 1. 서론

전 세계적으로 기후온난화에 따른 위험비용이 점점 커지고 있음에 따라 기후변화협상과 교토의정서를 통해 선진국을 필두로 대부분의 나라들이 지구 온난화를 극복하기 위해 노력하고 있다. 온난화 및 기후변화의 주요 원인이 이산화탄소 등 산업화에 따른 온실가스의 배출이라는 것이 밝혀지면서, 1997년 처음 채택된 교토의정서에서는 제1차 온실가스 감축의무기간(2008년~2012년) 중 감축목표를 1990년 대비 평균 5.2%로 설정하였다. 또한 감축 의무가 있는 주체들에게 감축의 인센티브 제공 및 감축 장려를 위해 교토메커니즘을 설정하였다. 교토메커니즘은 선진국이 개도국 온실가스 감축사업을 통해 탄소배출권을 확보할 수 있는 청정개발 메커니즘(Clean Development Mechanism: CDM), 선진국간의 온실가스 감축사업을 통해 탄소배출권을 확보하는 공동이행제도(Joint Implement: JI), 탄소배출권을 상호간 거래할 수 있는 국제배출권 거래로 이루어져 있다. 이러한 배경을 바탕으로 온실가스 중에서 가장 많은 부분을 차지하는 이산화탄소의 거래 즉, 탄소배출권 거래는 1990년대 말부터 시작되었으나 2005년 초반 교토의정서가 발효되기 이전까지는 조직화되고 규범화된 거래소가 아닌 장외거래를 중심으로 이루어졌다. 하지만 2005년 4월 유럽기후거래소(ECX: European Climate Exchange)가 출범함에 따라 탄소배출권 거래가 본격적으로 시작되었으며 거래량도 급증하였다.

탄소배출권 거래는 온실가스 배출 감축의무 주체가 직접적으로 감축활동을 하지 않고 시장거래를 통해 탄소배출권을 구매함으로써 감축 목표량의 일부 또는 전체를 인정받을 수 있는 거래제도이다. 유럽공동체(EU)에서 유럽 배출권시장(EU-ETS: European Emissions Trading Scheme)을 설립한 이후 거래가 매우 활발하게 이루어지고 있다. 이 중 대표적인 탄소배출권 거래 시장은 EU-ETS와, 미국의 CCX(Chicago Climate Exchange), 그리고 호주의 NSW(New South Wales) 등이 있다.

교토의정서에서는 각국이 할당하여 거래되는 배출권을 AAUs(Assigned Amount of Units)라고 한다. 특히 EU-ETS에서는 거래되는 배출권은 EUAs(European Union Allowances)라고 하며, EUAs 1단위는 이산화탄소 1톤 배출권을 의미한다. 이러한 EUAs의 활발한 거래를 계기로 탄소 배출권과 관련된 많은 학자들이 이 분야에 관심을 가지고 연구를 진행하고 있으며, 최근 국내에서도 EU-ETS의 자료를 바탕으로 여러 관점에서 다양한 연구 결과가 발표되고 있다.

## 2. 연구의 필요성

지금까지의 기후변화협상에 의하면 우리나라는 비부속서 I (Non-Annex I) 국가로서 현재 온실가스 배출량 감축의 의무부담국(Annex I)에 속해 있지 않지만, 향후 협상 여하에 따라 의무부담국에 편입되거나 자발적인 감축목표 설정하는 등의 방식으로 실질적인 온실가스 감축 정책을 추진해야 할 것으로 예상되고 있다[1]. 따라서 다가오는 가까운 미래에 온실가스 배출량 감축의 의무를 부담하게 될 국가임이 분명한 우리나라에서도 앞으로 참여하게 될 탄소배출권 거래시장에 대비해 많은 연구가 이루어져야 할 것이다.

실제로 주식, 채권 등의 유가증권처럼 거래가 이루어지는 탄소배출권 거래제도는 비용효율적인 온실가스 감축 수단임에 분명하다. 지금과 같은 정부의 직접 규제 하에서 각 산업의 자체적인 감축 수단만을 활용할 경우보다 탄소배출권 거래 제도를 시행하였을 경우 이산화탄소 저감비용이 약 60% 정도 절감되는 경제적 효과를 누릴 수 있는 효용이 있다[3]. 이렇게 탄소배출권 거래 시장이 국내에 시행됨으로써 누릴 수 있는 큰 파급효과와, 온실가스 배출량 감축 의무부담국으로의 편입이 예상되는 현실을 감안한다면 탄소배출권 거래제도의 도입에 따른 탄소배출권의 시장 가격형성 메커니즘(Mechanism)을 분석해야 할 필요성이 있다. 특히 탄소배출권의 적정가격을 도출하고 이를 이용하여 탄소배출권 시장의 과열 또는 침체 상황을 판단할 수만 있다면 정책적으로 매우 유용한 일이 될 것임에 틀림없다.

현재 세계적인 탄소배출권 거래시장의 규모와 배출권의 거래량을 기반으로 EUAs가 탄소배출권의 대표적인 가격지표로 인식되고 있는 가운데, 이러한 EUAs 데이터를 이용하여 탄소배출권 시장을 분석하는 시도가 최근 활발히 진행되고 있다.

국내의 연구를 살펴보면, 김수이[1]는 탄소배출권 가격이 석탄이나 가스 같은 화석원료보다 유가와 높은 상관관계를 가지고 있다는 사실을 밝혀 냈으며, 일별 가격 데이터뿐만 아니라 주별 가격 데이터 또한 매우 밀접한 관계를 형성하고 있다고 주장하였다. 이재우[2]는 EU-ETS에서 거래되고 있는 탄소배출권의 가격요인을 단기 및 중기적 요인을 중심으로 분석하였으며, 임청룡과 김태균[4]은 탄소배출권 가격과 철강기업 주가의 인과관계를 연구하였다.

이와 같은 국내 연구 이외에 탄소배출권 시장을 분석하는 다양한 국외 연구들도 진행되어 왔는데, Mansanet-Bataller 외[12]는 탄소배출권 가격의 변동성이 오

일, 가스, 석탄과 같은 화석에너지 가격뿐만 아니라 날씨와도 밀접한 관계가 있다는 사실을 밝혀 냈다. Alberola 외[6]는 탄소배출권 가격의 움직임을 구조적으로 분석하기 위해 화석에너지 가격과 날씨 데이터를 이용하여 탄소배출권 가격 흐름이 변하는 시점 (Structural Break Points)을 분석하는 모형을 제안하였다. Zhang과 Wei[15]는 EU-ETS 탄소배출권 거래시장의 운영 메커니즘과 경제적 효과를 조사하여 발표하였으며, Feng 외[9]는 탄소배출권 시장에 영향을 미치는 외생변수들에 대하여 연구 발표하였다. 또한, Oberndorfer[13]는 EUAs 가격 움직임과 전자회사주가의 수익률 간의 상관관계에 대하여 연구하였으며, Benz와 Truck[7]는 탄소배출권 가격움직임의 이분산성(Heteroscedasticity)을 확인하기 위해 Markov-switching 모델과 AR(1)-GARCH(1,1) 모델을 이용하여 탄소배출권 가격 흐름을 분석하였다.

하지만 위에서 살펴본 것처럼 탄소배출권 시장에 관한 기존 국내외 연구들은 대부분 탄소배출권 가격과 화석에너지 가격이나 날씨와 같은 외생변수들의 상관관계를 분석하거나 탄소배출권 시장의 메커니즘을 분석하는 것에 초점을 맞추고 있다. 기존 연구들은 탄소배출권 시장의 특성을 파악하거나 탄소배출권 가격에 영향을 미치는 요인을 찾으려는 시도일 뿐, 이러한 분석결과를 이용하여 탄소배출권 가격 자체를 예측하려는 시도는 찾아보기 힘들었다. 따라서 본 연구에서는 탄소배출권 가격데이터와 탄소배출권 가격과 가장 밀접한 관계를 가지고 있는 것으로 밝혀진 유가데이터, 그리고 이러한 데이터들을 바탕으로 생성된 파생변수들을 이용하여 탄소배출권 가격을 예측하는 모델을 개발하고자 한다.

### 3. 본 연구에서 사용된 방법론

#### 3.1 능형회귀분석(Ridge Regression)

통계적 분석방법 중 가장 일반적인 분석모형인 회귀분석에서 설명변수(입력변수)들 사이에 선형적 또는 거의 선형적인 종속관계가 있는 경우를 다중공선성(Multicollinearity)이라고 하며, 이는 설명변수들간의 독립성을 기본 가정으로 하는 회귀분석을 통한 추정 값에 왜곡을 가져오는 대표적인 요인이다. 통계적으로 다중공선성을 제거하는 가장 간단한 방법은 선형회귀 모형에 사용된 설명변수들의 개수를 줄이는 것이다. 하지만 설명변수의 개수를 줄이는 경우, 회귀관계의 구조를 확인하려는 것이 분석의 목적일 때에는 타당한 방법이라 할 수 없으며, 설명변수를 줄이기 위해 선택되는 방법들이 적당한 회귀모형을 선택치 못하게

하는 상황이 발생할 수 있다는 단점이 있다[5]. 회귀분석을 위한 회귀모형의 계수는 일반적으로 최소제곱 (Ordinary Least Squares: OLS)에 의해서 추정하게 되는데, 설명변수들이 서로 관련을 이루고 있는 경우에는 최소제곱에 의한 여러 설명변수의 추정계수는 잘못된 결과를 가져오게 된다. 이러한 문제점을 극복하기 위한 분석방법으로 Hoerl과 Kennard[10]에 의해 제안된 능형회귀분석이 유용하게 사용되고 있다. 즉, 능형회귀분석은 불안정한 상태의 OLS 회귀계수보다 안정적인 해를 얻기 위한 방법으로, 회귀분석의 틀과 원래의 설명변수 개수를 유지하면서 회귀계수의 추정량을 얻기 위한 통계적 알고리즘이다[8].

능형회귀분석에서의 회귀추정량(능형회귀추정량)을 얻기 위해 먼저 일반적인 회귀분석의 방정식을 생각해 보면  $y = X\beta$  와 같이 나타낼 수 있다. 이때, 행렬  $XX'$  의 고유값들이 식(1)을 만족한다고 하자. 여기서  $X'$  는  $X$  의 전치행렬이다.

$$\lambda_0 \geq \lambda_1 \geq \dots \lambda_p (\geq 0) \quad (1)$$

그러면 OLS 추정량  $\hat{\beta}$  의 평균제곱오차(Mean Squared Error)는 식(2)와 같다.

$$\begin{aligned} E(\|\hat{\beta} - \beta\|^2) &= E[(\hat{\beta} - \beta)'(\hat{\beta} - \beta)] \\ &= E[\text{trace}(\hat{\beta} - \beta)'(\hat{\beta} - \beta)] \\ &= \text{trace}[\sigma^2 (XX')^{-1}] \\ &= \sigma^2 \sum_{i=0}^p \frac{1}{\lambda_i} \end{aligned} \quad (2)$$

만약 설명변수들 사이에 다중공선성이 존재하면, 고유값들의 최소값  $\lambda_p$  가 0에 가까울 것이므로  $E(\|\hat{\beta} - \beta\|^2)$  이 클 것이다. 따라서 OLS 추정량  $\hat{\beta}$  은 회귀계수벡터  $\beta$  로부터 멀리 떨어져 있게 되므로 좋은 추정량이라 할 수 없다. 이와 같은 최소제곱추정량의 단점을 보완하기 위해서 Hoerl & Kennard[10]는 식(3)과 같은 능형회귀추정량을 제시하였다.

$$\hat{\beta} = (XX' + \lambda I)^{-1} X'y \quad (\lambda \geq 0) \quad (3)$$

여기서 일반적으로 능형모수(Ridge Parameter)  $\lambda$  는  $[0, 1]$  구간에 있다고 가정한다.

### 3.2 인공신경망(Artificial Neural Network)

기존의 통계학적 모델이 주식가격과 같은 비선형적인 특성을 가지는 금융시장에서의 시계열 자료 분석에 한계를 보여 줌에 따라 학자들 사이에서 비선형적 관계를 표현할 수 있는 인공신경망 모델이 주목을 받게 되었다. 인공신경망은 인간의 뇌신경의 정보처리 및 전달과정을 모방하여 구현한 모델이다. 다시 말하면, 실제로 패턴 분류, 함수 근사 등 수학적 정의가 명확하지 않는 문제들은 순차적인 알고리즘을 통해 처리할 경우 해를 구하는 과정에 막대한 계산 시간이 소요되어 비효율적이게 되는데, 인간의 뇌는 정보를 대규모로 병렬처리할 수 있는 특성으로 인해 자료들간의 전체적인 관계를 파악하는 종합적인 작업에 유리하다는 점에 착안하여 인공신경망이 개발되었다.

<그림 1>에서 볼 수 있듯이 일반적으로 인공신경망은 입력층(Input Layer), 은닉층(Hidden Layer), 출력층(Output Layer)으로 구성되는데, 입력층의 입력노드 값인  $X_1$  부터  $X_n$  까지의 값에 각각  $w_1$  부터  $w_n$  까지의 가중치를 곱하고, 그 모든 합이 은닉층에서 더해지게 되며, 그 모든 합은 전이함수(Transfer Function 또는 Activate Function)를 통해 일정한 임계치를 초과하게 되면 출력값이 발생하게 된다.




그림 1. 일반적인 인공신경망의 구조

입력층과 출력층에 각각 입력변수와 출력변수를 놓고 학습(Learning 혹은 Training)이 진행되며, 학습시에 생성되는 분류(예측) 값과 실제 값과의 차이를 줄이는 과정을 통해 최종 분류(예측) 값에 도달한다. 은닉층에

서 출력층으로 넘어갈 때 <그림 2>와 같은 다양한 전이함수들을 통해 값들이 변환되며 시계열데이터의 분석을 위해서는 본 연구에서 적용한 Sigmoid 함수가 가장 일반적으로 사용된다.




그림 2. 인공신경망에 사용되는 대표적인 전이함수들

인공신경망의 구조는 대부분의 경우 <그림 1>에서 보여 주고 있는 다층퍼셉트론(Multi-layer Perceptron)을 이용하며, 알고리즘으로는 역전파학습법(Backpropagation Neural Network; BPN)을 사용한다. BPN 알고리즘은 1980년대 후반에 Rumelhart 등[14]이 소개한 이후, 이학 및 공학 분야를 비롯한 재무, 정보시스템 및 계량경제 분야에 이르기까지 다양하게 활용되고 있으며 본 연구에서도 BPN 알고리즘을 이용하였다.

### 3.3 유전자 알고리즘(Genetic Algorithm)

Holland[11]에 의해 처음 소개된 유전자 알고리즘(Genetic Algorithm)은 인공신경망과 더불어 대표적인 인공지능 기법으로 알려져 있으며, 생물진화의 원리로부터 착안하여 확률적 탐색이나 학습 및 최적화를 위한 기법이다. 유전자 알고리즘의 주요 목적은 국소탐색이 아닌 전역탐색(Global Search)를 통해 최적해를 찾는 것이며 일반적으로 선택(Selection), 교차(Crossover), 그리고 돌연변이(Mutation), 이렇게 세 가지 종류의 유전자 조작(Genetic Operation) 과정을 사용하여 최적해를 탐색해 나간다. <그림 3>에서 볼 수 있는 것처럼 무작위로 생성된 초기집단(일반적으로 이진수 코드로 구성된 일차원의 배열들로 표현됨)으로부터 앞서 언급한 세 가지 유전자 조작을 사용하여 실험자가 설정한 종료 조건이 만족될 때까지 선택, 교차, 돌연변이 조작과정을 계속 반복하여 최적해를 탐색해 나가게 된다.

선택조작 과정은 최종 목표로 하는 적합함수(Fitness Function)를 최적화시키는 해를 확률적으로 발전시키는 단계로, 초기집단으로부터 발전된 집단을 형성시키게 된다. 교차조작 과정은 유전자 알고리즘에서 가장 중요한 단계로, 발전된 집단에 속해 있는 배열들간에 이진수 코드를 교차시킨다. 마지막으로 돌연변이 조작과정에서는 각 배열들 자신이 가지고 있는 코드를 무

작위로 바꾸게 됨으로써 자손집단(Offspring Set)을 형성시킨다. 이렇게 생성된 자손집단에 포함된 배열을 적합함수에 적용시켜 최적해를 탐색해 나가게 되는 것이다.

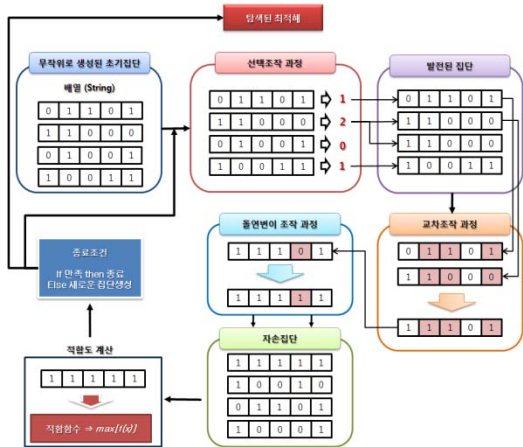


그림 3. 일반적인 유전자 알고리즘의 최적해 탐색 과정

#### 4. 탄소배출권 가격 예측모델의 구축 절차

본 연구에서 제안하는 모델의 구축과정은 <그림 4>와 같이 크게 실험 데이터 셋팅, 능형회귀분석과 인공신경망을 이용한 탄소배출권 가격 예측값 도출, 그리고 마지막으로 유전자 알고리즘을 이용한 하이브리드 모형 구축으로 이루어져 있다. 본 장에서는 제안 모델의 간단한 설계과정을 설명하며, 자세한 내용은 제5장에서 실증분석과 함께 기술한다.



그림 4. 제안된 탄소배출권 가격 예측모델 절차

##### 절차 1: 데이터 셋팅

탄소배출권 가격의 대표지표로 인식되고 있는 EUAs 데이터와 탄소배출권 가격과 가장 밀접한 관련이 있

다고 밝혀진 유가 데이터 중 가장 일반적인 지표인 WTI(West Texas Intermediate) Index를 기본으로 하여 파생변수들을 생성한다. 이렇게 생성된 파생변수들과 EUAs 및 WTI index 데이터들은 제안하고자 하는 탄소배출권 예측 모델의 입력변수로 사용된다. 또한 실험 설계시 훈련기간(Training Period)으로 설정된 구간에서는 Sliding Window Method를 이용하여 예측모형을 구축한다. 예측하고자 하는 탄소배출권 가격 데이터는 시계열 자료이기 때문에 예측기간과 가까운 기간에 일어난 사건에 대하여 더욱 큰 영향을 받을 확률이 높은 특성이 가지고 있다. 따라서 훈련기간을 예측기간(Forecasting Period) 또는 테스트기간(Testing Period)의 움직임에 맞추어, 같은 구간 폭으로 움직이면서 모형이 구축된다. <그림 5>는 본 연구에서 사용된 Sliding Window Method를 도식화하여 보여 주고 있다.

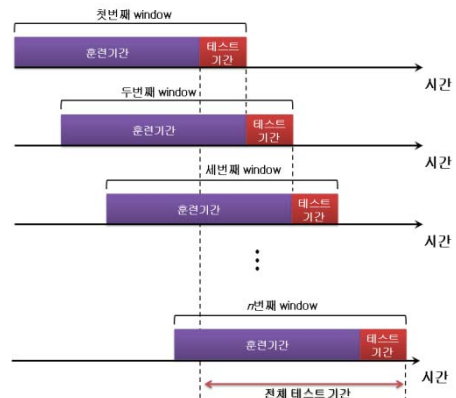


그림 5. Sliding Window Method

##### 절차 2: 테스트 구간에서의 예측값 도출

훈련기간 동안 절차 1에서 생성된 입력변수를 바탕으로 Sliding Window Method를 통해 실시된 능형회귀분석 모형과 인공신경망 모형을 각각 이용한 예측 모형을 만든다. 그리고 이렇게 만들어진 모형을 이용하여 테스트 구간에서의 예측값을 도출한다.

본 단계에서 능형회귀분석과 인공신경망을 이용하여 예측값을 도출하는 이유는 능형회귀분석의 가장 큰 장점인 입력변수들간에 다중공선성 관계가 있을 경우에 일반회귀분석을 통한 예측값은 신뢰가 떨어진다는 문제점을 보완하기 때문이다. 본 연구에서 사용되는 입력변수들은 대부분이 원 계열에서 얻어진 파생변수이기 때문에 변수들간의 다중공선성 문제가 발생한다. 또한 대표적인 인공지능 기법에 속하는 인공신경망의 경우 입력변수들간의 다중공선성이나 예측

하려는 시계열의 정상성(Stationarity) 여부와 같은 제한 조건을 고려하지 않고 분석할 수 있는 모형이기에 본 연구에서 예측모형으로 선택하였다. 따라서 이러한 예측기법의 선택은 본 연구의 분석대상인 EUAs의 가격 특성에 기인한 것이라 할 수 있다.

### 절차 3: 유전자 알고리즘을 이용한 하이브리드 예측 모형 개발

본 연구에서는 최종적으로 유전자 알고리즘을 이용하여 능형회귀분석과 인공신경망으로부터 도출된 예측값들에 가중치를 정하여 두 알고리즘이 결합된 최적의 예측값을 얻을 수 있는 하이브리드 예측모형을 개발한다. 이러한 예측값 결합 과정을 거침으로써, 제안된 예측모형은 예측기간의 각 Window 구간의 데이터 성격에 따라 능형회귀분석과 인공신경망 중 더 적합한 분석 알고리즘에 큰 가중치를 할당하게 된다. 따라서 본 연구에서 제안하는 탄소배출권 가격 예측모형은 능형회귀분석으로 대표되는 통계적 방법론의 장점과 인공신경망으로 대표되는 인공지능기법의 장점을 모두 취할 수 있으며, EUAs 가격데이터에 민감하게 반응할 수 있는 특성을 가질 수 있게 될 것으로 기대할 수 있다. 여기서 훈련기간 동안 각 알고리즘에서 도출된 예측가격의 가중치 최적화를 위해 설정되는 적합함수는 식(4)와 같이 나타낼 수 있다.

#### Fitness function (4)

$$= \min \sum_{i=1}^n [y_i - (wRR(T_i) + (1-w)NN(T_i))]^2$$

여기서  $y_i$  는  $i$  시점에서의 실제 EUAs 가격,  $RR(T_i)$  와  $NN(T_i)$  는 각각  $i$  시점에서의 능형회귀분석과 인공신경망으로부터 도출된 EUAs 가격 예측값, 그리고  $w$  는 유전자 알고리즘을 이용하여 탐색되는 최적 가중치이며 0과 1 사이의 값을 가진다.

## 5. 실증분석

### 5.1 실험 설계

본 연구에서 가장 중요한 변수인 EUAs와 WTI 데이터는 한국증권전산(KOSCOM)에서 제공하는 데이터를 이용하였으며, 총 분석 기간은 2008년부터 2011년 데이터를 사용하였다. 2005년부터 2007년도까지에 해

당되는 제1차 탄소배출권 시장 시기는 EU-ETS로부터의 EUAs 과다 공급으로 인해 가격 데이터의 흐름이 왜곡되었기 때문에 2008년도 이전 데이터는 사용하지 않았다. 또한 탄소배출권 시장의 특성상 가격 데이터의 변동성이 주식시장이나 환율시장과 같은 금융시장처럼 크지 않기 때문에 일별 데이터 대신 주별 데이터가 분석에 사용되었다. 제안된 탄소배출권 가격 예측모형의 구축을 위해 사용되는 훈련기간과 테스트기간은 각각 12개월과 1개월로 설정하여 Sliding Window Method를 이용해 실험이 진행되었으며, 아래의 <표 1>에 그 기간들이 구체적으로 명시되어 있다.

표 1. 모델구축을 위한 훈련기간과 검증을 위한 테스트 기간

Window 번호	훈련기간	테스트 기간
1	2009.11 ~ 2010.10	2010.11 ~ 2010.11
2	2009.12 ~ 2010.11	2010.12 ~ 2010.12
3	2010.01 ~ 2010.12	2011.01 ~ 2011.01
4	2010.02 ~ 2011.01	2011.02 ~ 2011.02
5	2010.03 ~ 2011.02	2011.03 ~ 2011.03
6	2010.04 ~ 2011.03	2011.04 ~ 2011.04
7	2010.05 ~ 2011.04	2011.05 ~ 2011.05
8	2010.06 ~ 2011.05	2011.06 ~ 2011.06
9	2010.07 ~ 2011.06	2011.07 ~ 2011.07
10	2010.08 ~ 2011.07	2011.08 ~ 2011.08
11	2010.09 ~ 2011.08	2011.09 ~ 2011.09
12	2010.10 ~ 2011.09	2011.10 ~ 2011.10

제안된 예측모형에서 사용된 입력변수들은 원계열인 EUAs와 WTI 그리고 각 원 계열에서 파생된 변수들로 구성되며, <표 2>, <표 3>과 같이 설명할 수 있다.

표 2. 실증분석에 사용된 파생변수 수식 및 설명

변수	수식	설명
IDX	$x_t$	원 계열
WRF	$p_t = \frac{x_t - x_{t-1}}{x_{t-1}}$	주별 수익률



MA(m)	$\bar{p}_{m,t} = \sum_i^t \frac{p_i}{m}$ $i = t - (m - 1)$	m일 이동평균
MV(m)	$s_{m,t}^2 = \sum_i^t \frac{(p_i - p_{m,t})^2}{m}$ $i = t - (m - 1)$	m일 이동분산

표 3. 실증분석에 사용된 변수 및 설명

변수	변수
입력변수	IDX <sup>EUAs</sup> , MA(5) <sup>EUAs</sup> , MA(20) <sup>EUAs</sup> , MA(60) <sup>EUAs</sup> , MV(5) <sup>EUAs</sup> , MV(20) <sup>EUAs</sup> , MV(60) <sup>EUAs</sup> , WRF <sub>WTI</sub> , IDX <sub>WTI</sub> , MA(5) <sub>WTI</sub> , MA(20) <sub>WTI</sub> , MA(60) <sub>WTI</sub> , MV(5) <sub>WTI</sub> , MV(20) <sub>WTI</sub> , MV(60) <sub>WTI</sub> ,
종속변수	WRF <sup>EUAs</sup>

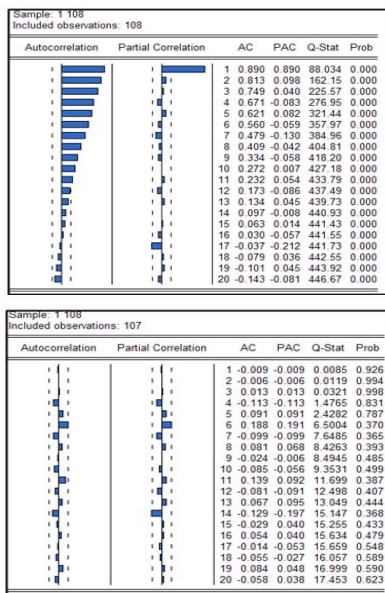


그림 6. 탄소배출권 가격 원계열 및 수익률 데이터의 상관도  
(위: 원계열, 아래: 수익률)

여기서 중요한 점은 <표 3>에서 나타난 것처럼 종속변수를 EUAs의 원계열로 설정하지 않고 수익률로 설정했다는 것이다. 이는 탄소배출권 가격 예측시 회귀분석이나 능형회귀분석과 같은 통계적 기법을 이용

하기 때문에 분석하려는 시계열의 정상성을 확보하기 위함이다. <그림 6>은 수익률로 변환한 예측변수 데이터가 원계열에 비해 월등한 정상성을 가지는 시계열임을 보여 주고 있다.

## 5.2 실험 결과 및 분석

앞서 살펴본 실험 설계 방법으로 회귀분석과 능형회귀분석, 그리고 인공신경망 모형을 이용하여 탄소배출권 가격의 예측값을 도출한 후 테스트기간 동안의 예측오차를 살펴보았다. 본 연구에서는 예측오차지표로 일반적으로 가장 널리 이용되는 MAPE(Mean Absolute Percentage Error)를 사용하여 각 모형간의 성과를 비교한다. MAPE는 예측오차의 값이 백분율로 표현되기 때문에 모형간 예측오차 차이가 비교적 커지게 됨으로써 실험자에게 성과 비교를 쉽게 할 수 있도록 해주는 장점이 있으며, 계산 방식은 식(5)와 같다.

$$MAPE = \frac{1}{n} \sum_{t=1}^n \left| \frac{Y_t - \hat{Y}_t}{Y_t} \right| \times 100 \quad (5)$$

여기서  $Y_t$ 는 t 시점에서의 실제값이며,  $\hat{Y}_t$ 는 t 시점에서의 예측값이다.

전체 테스트기간 동안의 각 모형으로부터 도출된 MAPE 값은 <표 4>에 나타나 있으며, 각 Window 구간에서 MAPE 값의 흐름은 <그림 7>에서 보여 주고 있다. <표 4>에 나타나 있는 것처럼 회귀분석을 통해 예측된 결과보다는 능형 회귀분석을 통해 예측된 결과가 더 좋다는 것을 알 수 있다. 이는 예측모형에 사용된 파생변수들 때문에 입력변수들간에 다중공선성이 존재하기 때문에 이 문제점을 고려한 능형회귀분석의 예측오차가 더 우수한 결과를 보여 주는 것이라 할 수 있다. 또한 이러한 능형 회귀분석보다 인공신경망을 사용했을 때 더욱 좋은 MAPE 값을 가지게 되는데, 이는 실험기간 동안의 탄소배출권 가격 데이터가 비선형적인 특성을 강하게 가지고 있다는 사실을 뒷받침해 주는 결과라고 판단된다. 일반적으로 비선형 데이터의 특성을 가지는 시계열 분석시 전통적인 통계적 기법보다는 인공지능 기법을 사용함으로써 더욱 좋은 성과를 기대할 수 있는데, 특히 주식가격, 환율 및 파생상품과 같은 금융 분야의 데이터 분석 사례에서 잘 알려져 있다.

표 4. 전체 테스트기간 동안의 예측오차

	회귀분석	능형회귀분석	인공신경망
MAPE	284.25	150.11	122.18




그림 7. 각 테스트(Window) 구간에서 단일모형의 예측오차

<그림 7>을 통해서도 대부분의 Window 구간에서 인공신경망 모형이 가장 좋은 성과를 보이고 있는 것을 알 수 있으나, window\_no.2와 window\_no.12 구간에서 능형회귀분석의 예측오차가 인공신경망보다 줄어들었다는 사실을 알 수 있다. 이러한 사실을 통해 인공신경망 모형을 단독으로 사용하는 것보다 능형회귀분석 모형을 결합함으로써 더 좋은 성과를 낼 수 있다는 가능성을 확인할 수 있었다. 따라서 능형회귀분석과 인공신경망의 예측값에 각각 가중치를 주어 결합된 예측값을 도출하는 방법으로 하이브리드 예측모형을 구축하였다. 이때 최적 가중치는 훈련기간 동안 유전자 알고리즘을 이용하여 본 연구에서 설정한 적합도 함수(제3장 제3절 참조)를 통해 계산되며, 이렇게 계산된 가중치로 구성된 하이브리드 모형의 예측오차는 아래의 <표 5>와 같으며 앞에서 가장 좋은 결과를 보여 준 인공신경망의 MAPE의 값과 비교하였다. 그리고 <표 6>은 각 Window 구간에서 유전자 알고리즘을 통해 도출된 최적의 가중치이다.

표 5. 전체 테스트기간 동안의 인공신경망과 하이브리드 모형 간 예측오차

	인공신경망	하이브리드
MAPE	122.18	99.38

표 6. 각 테스트 구간별 유전자 알고리즘을 통해 도출된 가중치

Window 번호	능형회귀분석	인공신경망
1	0.167236	0.832764
2	0.978937	0.021063
3	0.000185	0.999815
4	0.138248	0.861752
5	0.00153	0.99847
6	0.00771	0.99229
7	0.00098	0.99902
8	0.002287	0.997713
9	0.000115	0.999885
10	0.002841	0.997159
11	0.000306	0.999694
12	0.999141	0.000859




그림 8. 각 테스트(Window) 구간에서 주요모형의 예측오차

마지막으로 <그림 8>은 본 연구에서 최종적으로 제안한 하이브리드 예측모형의 MAPE 값을 능형회귀분석, 인공신경망 모형과 비교할 수 있도록 각 Window 구간에서 보여 주고 있다. 그래프를 통하여 예측오차의 값을 살펴보면 각 Window 구간에서 능형회귀분석과 인공신경망 모형의 예측오차 중 더 우수한 값에 수렴하는 듯한 모습을 보이고 있으며, 이는 유전자 알고리즘을 통해 탐색된 가중치가 하이브리드 모형의 예측오차를 줄이는 방향으로 올바르게 도출되었다는 것을 의미한다고 볼 수 있다.



## 6. 결론 및 한계점

본 연구의 목적은 탄소배출권 거래시장 특성이 반영된 탄소배출권 가격 예측모델 개발이다. 따라서 본 연구에서는 탄소배출권 가격 예측을 위한 하이브리드 모형을 구축하였으며, 이를 기반으로 앞으로 국내에 정착될 탄소배출권 거래 시장을 대비함에 있어 하나의 방법을 제시하였다. 또한, 제안한 모형의 정확도를 판단하기 위하여 다른 예측 모델들과의 예측성차를 MAPE로 측정하여 비교하였으며, Sliding Window Method를 통해 모형의 유용성에 대해 검증하였다. 이와 같이 탄소배출권 가격을 예측함으로써 미래의 탄소배출권 가격에 대비할 수 있으며, 제안된 모형을 활용하여 배출권 가격의 예측값을 토대로 적정 탄소배출권 가격을 도출하는 데 있어 하나의 가이드라인으로서의 역할을 할 수 있을 것으로 기대된다. 또한 예측값을 이용하여 탄소배출권 시장의 과열 또는 침체 상황을 판단할 수 있다면 관련 분야에서의 정책 수립에 있어 매우 유용한 정보를 가져다 줄 것이라 생각된다.

본 연구의 의의는 다음과 같다. 첫째, 본 연구는 기존 연구들과 달리 탄소배출권 가격 자체를 예측하려는 모델을 제안하였다. 비록 탄소배출권의 주별 가격을 예측하였지만, 향후 더 장기간의 탄소배출권 가격 예측을 통하여 각 국가 및 기업들은 이에 대한 예상 비용을 상정하여 위험관리에 대비할 수 있을 것이다. 둘째, 본 연구에서 제안한 하이브리드 예측 모형은 통계적 기법과 인공지능기법의 특성을 모두 고려한다는 장점을 가지고 있으며, 이는 탄소배출권 거래시장 데이터와 같은 비선형적인 특징을 가지는 데이터의 분석시 매우 유용할 것으로 기대된다.

앞으로 이와 관련되어 추가로 연구되거나 보완되어야 할 사항들은 다음과 같다. 본 연구에서는 단순히 유가와 탄소배출권, 파생된 변수들을 가지고 가격을 예측하였지만, 기존 국내의 연구들에서 살펴본 탄소배출권 가격에 영향을 미치는 요인들을 포함하여 더 정확도가 높은 가격 예측 모델을 개발하고자 한다. 또한 다른 분야에서도 본 연구가 제안한 모형을 적용해 보고, 그 유용성을 검증해 볼 필요가 있다.

## 참고문헌

[1] 김수이, 박호정, 2007. “배출권거래 가격결정요인 분석과 전망(화석연료가격과의 상관관계를 중심으로)”, 기본 연구보고서 07, 에너지경제연구원.

[2] 이재우, 2008. “EU-ETS 탄소배출권 가격 결정요인 분석: 단기 및 중기적 요인을 중심으로”, 해외경제 보고서, 한국수출입은행.

[3] 이지훈, 2009. “탄소배출권 거래제의 경제적 효과”, 266호, SERI 경제 포커스.

[4] 임청룡, 김태균, 2010. “탄소배출권 가격과 철강기업 주가의 인과관계”, *에너지경제연구*, 제9권, 1호, pp.1-23.

[5] 최병선, 1997. *회귀분석*, 세경사.

[6] Alberola, E., Chevallier, J. and Chèze, B., 2008. “Price drivers and structural breaks in European carbon price 2005–2007”, *Energy Policy*, Vol.36, No.2, pp.787-797.

[7] Benz, E. and Truck, S., 2009. “Modeling the price dynamics of CO2 emission allowances”, *Energy Economics*, Vol.31, No.1, pp.4-15.

[8] Chatterjee, S., Hadi, A.S. and Price, B., 2006. *Regression analysis by example*, 4th ed., John Wiley & Sons.

[9] Feng, Z., Zou, L. and Wei, Y., 2011. “Carbon price volatility: Evidence from EU ETS”, *Applied Energy*, Vol.88, No.3, pp.590-598.

[10] Hoerl, A.E. and Kennard, R.W., 1970. “Ridge regression: biased estimation for non-orthogonal problems”, *Technometrics*, Vol.12, pp.55-67.

[11] Holland, J.H., 1975. *Adaptation in natural and artificial systems: an introductory analysis with applications to biology, control and artificial intelligence*, The MIT Press.

[12] Mansanet-Bataller, M., Pardo, A. and Valor, E., 2007. “CO<sub>2</sub> prices, energy and weather”, *The Energy Journal*, Vol.28, No.3, pp.67-86.

[13] Oberndorfer, U., 2009. “EU emission allowances and the stock market: evidence from the electricity industry”, *Ecological Economics*, Vol.68, No.4, pp.1116-1126.

[14] Rumelhart, D.E., McClelland, J.L. and the PDP Research Group, 2007. *Parallel distributed processing*, Cambridge, MA: MIT Press.

[15] Zhang, Y.J. and Wei, Y.M., 2010. “An overview of current research on EU ETS: evidence from its operating mechanism and economic effect”, *Applied Energy*, Vol.87, No.6, pp.1804-1814.

## 저자소개



**김영민**  
(Kim, Young Min)

연세대학교 정보산업공학과에서 박사학위를 취득하고 현재 Missouri University of Science and Technology, Department of Engineering Management and Systems Engineering에서 박사후과정에 있다. 주요 연구 관심 분야는 빅데이터 분석을 활용한 금융시장 분석 및センチメント 분석, 인공지능을 활용한 트레이딩 시스템 개발 등이다.

E-mail: wealth38@gmail.com

Tel: +82-2-415-4141



**안재준**  
(Ahn, Jae Joon)

연세대학교 정보산업공학과에서 박사학위를 취득하고 현재 연세대학교 정보통계학과 조교수로 재직중이다. 주요 관심 분야는 금융통계, 금융시계열, 데이터마이닝 및 빅데이터 분석 등이다.

E-mail: ahn2615@yonsei.ac.kr

Tel: +82-33-760-2766

◇ 이 논문은 2016년 1월 4일에 접수하여 2016년 2월 21일 1차 수정을 거쳐 2016년 2월 23일에 게재확정되었습니다.